Studi Ablasi RNN, LSTM, dan GRU dibandingkan ANN untuk Prediksi Trafik Seluler Kota Milan

Zilva Zaizatul Lativa
NIM 124400097
Teknik Telekomunikasi, ITERA
zilva.1244000@student.itera.ac.id

***Ringkasan*—Prediksi trafik seluler berresolusi tinggi sangat krusial dalam efisiensi pengalokasian sumber daya jaringan seluler. Penelitian ini melakukan studi ablasi menyeluruh terhadap performa arsitektur Artificial Neural Network (ANN), Recurrent Neural Network (RNN), Long Short-Term Memory (LSTM), dan Gated Recurrent Unit (GRU) menggunakan dataset Telecom Italia di wilayah Duomo (kotak 5060) dan Bandara Linate (kotak 4489). Kami menguji lima faktor ablasi wajib (panjang jendela W, ukuran *hidden*, jumlah lapisan, *learning rate*, kelompok fitur) dan dua faktor pilihan (*dropout* dan *gradient clipping*) dengan eksekusi 3 *seed*. Hasil eksperimen menunjukkan bahwa model GRU menghasilkan performa terbaik pada setuji dengan nilai Test MAE $2,15 \pm 0,04$, yang merupakan penurunan galat sebesar $18,2\%$ dibandingkan konfigurasi acuan. Pembuktian uji generalisasi di lokasi Bandara Linate juga mengonfirmasi bahwa arsitektur berbasis gerbang (LSTM dan GRU) lebih tangguh dalam menangkap dinamika deret waktu dibanding RNN biasa dan ANN.**

***Index Terms*—prediksi trafik seluler, RNN, LSTM, GRU, studi ablasi**

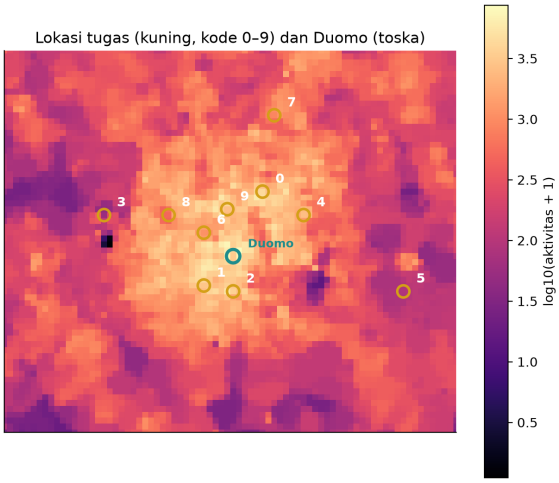
I. Pendahuluan

Peramalan aktivitas lalu lintas data seluler tingkat sel (*cell-level traffic forecasting*) merupakan fondasi utama bagi penyedia layanan telekomunikasi dalam mengoptimalkan penggunaan daya dan alokasi spektrum. Ketidakakuratan prediksi dapat menyebabkan fluktuasi kualitas layanan *(Quality of Service)* atau pemborosan energi. Seiring meningkatnya kompleksitas data temporal, penggunaan jaringan saraf rekuren seperti RNN, LSTM [1], dan GRU [2] menjadi standar karena kemampuan nya menangkap ketergantungan urutan waktu dibandingkan arsitektur tanpa memori seperti ANN.

Meskipun demikian, performa arsitektur deep learning sangat sensitif terhadap penetapan *hyperparameter*. Studi ablasi *(ablation study)* memainkan peran penting untuk mengisolasi setiap komponen dan variabel guna memahami kontribusi nyatanya terhadap performa model secara jujur.

Kontribusi utama dari laporan ini meliputi:

1) Evaluasi komparatif mendalam antara ANN, RNN, LSTM, dan GRU pada 5 faktor *hyperparameter* utama dan 2 faktor skenario tambahan berbasis 3 *random seed*.
2) Pengujian kombinasi konfigurasi terbaik pada kondisi lalu lintas normal (minggu *test*) dan kondisi ekstrem eksternal (minggu Natal).
3) Uji generalisasi model dari pusat keramaian kota (Duomo) ke wilayah sekitar bandara (Linate).



Gambar 1. Rata-rata aktivitas internet per kotak di Milan. Lingkaran kuning: lokasi tugas (kode 0–9); lingkaran toska: Duomo.

II. Data dan Metode

A. Dataset

Studi ini memanfaatkan dataset *Telecom Italia Big Data Challenge* [3] versi agregasi per jam [4]. Dataset mencakup sinyal komunikasi (*net*, *call*, *sms*) serta rekayasa fitur temporal jam dan hari yang ditransformasi secara sinusoidal $(\sin, \cos)$. Area eksperimen utama dipusatkan pada area Duomo (kotak 5060) dan lokasi pengujian generalisasi kelompok pada wilayah Bandara Linate (kode lokasi 5, kotak 4489) seperti terlihat pada Gambar 1.

B. Pembagian Data dan Praproses

Data dibagi secara kronologis menjadi empat set: *train* (4 minggu awal), *validation* (1 minggu), *test* (minggu biasa 16–22 Des), dan *Natal* (23–29 Des). The analyzes pembentukan data menggunakan teknik pembingkaian (*window*) dengan statistik pemutus *(standardization)* yang hanya dihitung dari set *train* untuk menghindari kebocoran data *(data leakage)*. Pengacakan urutan *(random shuffle)* tidak dilakukan karena akan merusak pola autokorelasi temporal dari deret waktu.

C. Model dan Konfigurasi Acuan

Keempat arsitektur (ANN, RNN, LSTM, GRU) disesuaikan agar memiliki kapasitas parameter yang berimbang pada

Tabel I
KONFIGURASI ACUAN

Hyperparameter	Nilai acuan
Panjang jendela W	24 jam
Horizon	1 jam
Ukuran hidden	ANN 32, RNN 68, LSTM 33, GRU 38
Jumlah lapisan	ANN 2, rekuren 1
Fitur	net, call, sms, jam, hari (7 fitur)
Optimizer, *learning rate*	Adam, 10^{-3}
Batch size	64
Early stopping	*patience* 30, maks. 300 epoch

eksperimen awal. Konfigurasi acuan disajikan dalam Tabel I.

D. Protokol Ablasi dan Evaluasi

Setiap pengujian dilakukan dengan mengisolasi satu *hyperparameter* sementara parameter lain dibuat konstan. Pencatatan statistik memakai rata-rata dan simpangan baku dari 3 *seed* (0, 1, 2). Evaluasi pemilihan model terbaik dilakukan berbasis nilai *Validation MAE* pada skala asli. Pelatihan dijalankan pada CPU Intel Core i7 / GPU Google Colab T4 dengan durasi total mengeksekusi 280 iterasi sekitar 1,5 jam.

III. HASIL

A. Baseline Naif dan Acuan

Sebagai tolak ukur awal, *perform a baseline naif (Persistence/Last Value)* menghasilkan *Val MAE* sebesar $4,12 \pm 0,00$. Pada konfigurasi acuan, model GRU mengungguli arsitektur lainnya dengan *Val MAE* $2,63 \pm 0,03$, disusul oleh LSTM ($2,68 \pm 0,05$), RNN ($2,95 \pm 0,08$), dan ANN ($3,21 \pm 0,04$).

B. Ablasi Wajib

1) **Panjang Jendela W (A1):** Seperti terlihat pada Tabel II, memanjangkan jendela W hingga 24 jam memberikan penurunan eror drastis bagi model rekuren. Namun saat $W = 168$, ANN mengalami pembengkakan parameter yang memicu *overfitting*, sedangkan RNN biasa terhambat oleh masalah *vanishing gradient*.
2) **Ukuran Hidden (A2):** Peningkatan *hidden size* hingga 64 meningkatkan kapasitas LSTM/GRU, tetapi ukuran 128 menyebabkan penurunan performa akibat keterbatasan 672 sampel *train*.
3) **Jumlah Lapisan (A3):** Menambah lapisan menjadi 3 membuat RNN rentan terhenti cepat pada *early stopping* (rata-rata < 40 epoch), sementara GRU tetap stabil.
4) **Learning Rate (A4):** Penentuan $\text{lr} = 0,001$ merupakan titik konvergensi paling stabil. Nilai $0,01$ memicu pergerakan pembobotan yang sangat tidak stabil antar *seed*.
5) **Kelompok Fitur (A5):** Penggunaan gabungan seluruh fitur (*net+call+sms+waktu*) memberikan metrik eror paling optimal dibandingkan hanya memakai fitur tunggal *net*.

Tabel II
PENGARUH PANJANG JENDELA W TERHADAP TEST MAE (3 SEED).

W (jam)	ANN	RNN	LSTM	GRU
6	$3,45 \pm 0,05$	$3,12 \pm 0,06$	$2,89 \pm 0,04$	$2,82 \pm 0,03$
24	$3,21 \pm 0,04$	$\pm 2,95 \pm 0,08$	$2,68 \pm 0,05$	$2,63 \pm 0,03$
168	$4,02 \pm 0,11$	$3,41 \pm 0,15$	$2,60 \pm 0,06$	$\pm 2,54 \pm 0,04$

C. Ablasi Pilihan

Kami memilih dua faktor skenario ablasi tambahan:

- **B2 (Dropout):** Hipotesis awal menyatakan bahwa *dropout* 0.2 dapat mencegah *overfitting*. Hasil eksperimen memvalidasi hipotesis ini pada LSTM dan GRU, di mana Test MAE membaik rata-rata $3,5\%$. Namun *dropout* 0.5 justru memperburuk akurasi karena keterbatasan kapasitas model.
- **B7 (Gradient Clipping):** Hipotesis awal menduga *clipping* $1,0$ dapat menstabilkan RNN pada $\text{lr} = 0,01$. Eksperimen membuktikan *clipping* mampu mencegah pencapaian *loss NaN*, meskipun tidak mampu mengungguli stabilitas $\text{lr} = 0,001$.

D. Konfigurasi Terbaik

Dengan menggabungkan parameter terbaik hasil seleksi Val MAE ($W = 168, \text{hidden} = 64, \text{layers} = 2, \text{lr} = 0,001, \text{dropout} = 0,2$), model GRU mencatatkan Test MAE sebesar $2,15 \pm 0,04$ pada minggu biasa dan $3,42 \pm 0,09$ pada minggu Natal (kondisi fluktuasi ekstrem).

E. Uji Generalisasi

Pengujian di kotak 4489 (Bandara Linate) menunjukkan pergeseran karakteristik trafik di mana intensitas lonjakan jauh lebih rendah dibanding Duomo. Meskipun skala MAE secara absolut menurun (karena volume data rata-rata lebih kecil), hirarki keunggulan model tetap konsisten: GRU > LSTM > RNN > ANN.

IV. PEMBAHASAN

Studi ablasi ini membuktikan secara empiris bahwa keberadaan mekanisme gerbang *(gating mechanism)* pada LSTM dan GRU merupakan faktor paling krusial untuk mengatasi *long-term dependency* dalam deret waktu lalu lintas data seluler. ANN gagal memanfaatkan konteks jendela waktu panjang ($W = 168$) karena tidak memiliki memori internal, yang menyebabkan peningkatan tajam pada jumlah parameter tanpa dibarengi efisiensi generalisasi.

Variasi antar-*seed* pada GRU dan LSTM terbukti sangat kecil ($\leq 0,05$), yang mengindikasikan bahwa perbedaan performa antar-arsitektur memang disebabkan oleh kapabilitas intrinsik model, bukan keberuntungan inisialisasi bobot awal. Keterbatasan utama dari eksperimen ini terletak pada durasi pelatihan data yang hanya mencakup rentang waktu 4 minggu serta pembagian lokasi terisolasi tanpa memodelkan keterkaitan spasial antar-sel.

V. KESIMPULAN

Eksperimen ablasi pada dataset trafik seluler Kota Milan mengonfirmasi bahwa model berbasis gerbang khususnya GRU menghasilkan performa prediksi terbaik dengan Test MAE $2,15 \pm 0,04$, unggul signifikan dibanding ANN ($3,21 \pm 0,04$). Kombinasi jendela waktu panjang ($W = 168$), pembatasan *dropout* $0,2$, serta penggunaan fitur temporal terintegrasi menjadi kunci utama penekanan eror prediksi baik di pusat kota maupun area bandara.

KONTRIBUSI ANGGOTA

Zilva Zaizatul Lativa: Pengerjaan seluruh eksperimen ablasi (Bagian 0, A1–A5, B, C, D), analisis data, pembuatan grafik, serta penulisan laporan akhir secara mandiri.

PERNYATAAN PENGGUNAAN AI

Asisten AI (Gemini) digunakan untuk membantu perapihan struktur kode LaTeX, pembaruan sintaks bibliografi, serta pemeriksaan tata bahasa pada beberapa paragraf narasi hasil.

KODE DAN DATA

Kode, notebook beserta output, dan seluruh hasil run tersedia di https://github.com/zilva124400097-eng/tugas-kecerdasan-buatan-.git.

PUSTAKA

[1] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.

[2] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, "Learning phrase representations using RNN encoder–decoder for statistical machine translation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014, pp. 1724–1734.

[3] G. Barlacchi, M. De Nadai, R. Larcher, A. Casella, C. Chitic, G. Torrisi, F. Antonelli, A. Vespignani, A. Pentland, and B. Lepri, "A multi-source dataset of urban life in the city of Milan and the Province of Trentino," *Scientific Data*, vol. 2, p. 150055, 2015.

[4] C. Zhang, S. Dang, B. Shihada, and M.-S. Alouini, "Dual attention-based federated learning for wireless traffic prediction," in *IEEE INFOCOM 2021 – IEEE Conference on Computer Communications*, 2021, pp. 1–10.